

RAG-Design_판교-10반_박성우+박인애+이승준+서지원+전은배+최윤영

목차

- A. 대상 기술
- B. 설계
- C. 평가 관점 및 기준
- D. 그래프 설계(안)
- E. 평가 보고서

KV Cache 최적화 기술 다관점 평가를 위한 Multi-Agent RAG 설계

프로젝트명: KV Cache 최적화 기술 다관점 평가 Agentic RAG

캠퍼스 / 반: 판교 / 10반

팀원: 박성우+박인애+이승준+서지원+전은배+최윤영

평가 도메인: 장문맥 처리 애플리케이션

A. 대상 기술

1. 프로젝트 목적

본 프로젝트는 장문맥 처리 환경에서 발생하는 KV Cache 병목 문제를 해결하는 두 기술을 비교·평가하는 Multi-Agent RAG 시스템을 설계한다.

평가 목적은 특정 기술의 우열을 단정하거나 최종 승자를 선정하는 것이 아니다. 기술 성숙도, 시장성, 이해관계자, 장문맥 처리 애플리케이션 적용성이라는 네 가지 관점에서 각 기술의 특성, 적용 조건, 장점과 한계를 근거 기반으로 분석하는 데 목적이 있다.

또한 두 기술은 적용 수준이 서로 다르므로, 논문에서 보고한 성능 수치를 단순히 직접 대결시키지 않는다. 대신 KV Cache 병목을 해결하는 방식, 필요한 시스템 조건, 메모리 효율, 정확도 보존 가능성, 처리 지연, 도입 난이도 등을 중심으로 비교한다.

2. 비교 대상 기술

선정 기준

- ① **범위 적합성:** SW는 모델 파라미터·아키텍처 수준에서 KV Cache를 축소하는 방식, HW는 GPU 외부 메모리 계층을 활용·확장하는 방식이어야 한다.
- ② **평가 가능성:** 공개 구현·실제 서비스 적용·커뮤니티 반응 등 4가지 관점(특히 시장성·이해관계자)을 채울 수 있는 근거가 있어야 한다. 논문 단계에 머문 기술은 제외한다.
- ③ **비교 가능성:** 상대 진영 대표 기술과 두 기술의 성능 수치를 직접 대결시키지 않고, 메모리 효율, 품질 보존 근거, 처리 지연, 적용 조건, 도입 난이도라는 공통 평가 관점에서 조건별 차이를 해석할 수 있어야 한다.

진영	후보	선정·미선정 사유	상태
SW	TurboQuant	기준② 미충족 — 양자화 기반 사후 압축 기법으로, 논문 단계에 머물러 실제 서비스 적용·채택 근거를 확인할 수 없음	미선정
SW	KIVI	기준② 미충족 — TurboQuant와 동일하게 연구 단계 기법으로, 시장성·이해관계자 관점을 채울 근거 부족	미선정
SW	DeepSeek-V2 MLA	기준①②③ 모두 충족 — 아키텍처 자체를 재설계하며, 실제 출시·배포 이력(DeepSeek-V3-R1 계보)이 있고, 압축-정확도 트레이드오프로 InfiniGen과 비교 가능	선정
HW	ITME	기준② 미충족 — 공개 구현·재현 정보가 부족해 동일 기준 평가가 어려움	미선정
HW	PIM/CXL	기준③ 미충족 — 메모리 계층 확장 중심의 접근으로, 본 과제의 비교 범위인 모델 구조 수준 KV Cache 절감과 동적 오프로딩·Prefetch 기반 관리보다 시스템하드웨어 범위가 넓어 동일한 평가 범위에서 근거를 수집하고 비교하기 어려움	미선정
HW	InfiniGen	기준①②③ 모두 충족 — 호스트 메모리 오프로딩으로 범위에 부합, 공개 Artifact 및 장문맥 성능·정확도 평가 근거 보유, 예측 실패 시 지연·정확도 트레이드오프로 비교 가능	선정

3. 기술 선정 사유

선정된 기술

DeepSeek-V2는 236B 파라미터(토큰당 21B 활성) 규모의 MoE 모델로, 128K 컨텍스트 길이를 정식 지원한다. 이 논문은 이전 모델인 DeepSeek 67B 대비 KV Cache를 93.3% 감소시켰다고 보고하며, 별도의 attention ablation에서 MLA의 성능을 MHA와 비교한다.

InfiniGen은 CPU 메모리에 KV Cache 전체를 유지하면서, 다음 토큰 생성에 필요한 항목만 예측해 GPU로 선택적으로 prefetch하는 Offloading 프레임워크다. InfiniGen 논문의 오프로딩 실험에서는 기존 KV Cache 관리 방식 대비 최대 3.00배의 성능 향상을 보고한다.

따라서, DeepSeek-V2 MLA와 InfiniGen을 최종 선정한 이유는 다음과 같다.

SW 진영 — DeepSeek-V2 MLA

우리 조는 압축률의 크기가 아니라, **그 압축 방식이 실제 서비스에 적용된 사례가 있는지를** 기준으로 판단했다.

TurboQuant·KIVI는 KV Cache를 더 적은 비트로 표현하는 사후 압축 기법으로 논문상 수치는 준수하지만, 연구 논문 단계에 머물러 있어 실제 채택 여부를 추적할 근거가 없다. 반면 DeepSeek-V2는 실제 출시·배포된 모델이며, 이후 DeepSeek-V3-R1 등 후속 모델로 이어지는 계보가 있어 커뮤니티 반응·다운로드·채택 사례를 실제로 추적할 수 있다. 4가지 평가 관점(특히 시장성·이해관계자) 모두를 공백 없이 채울 수 있는 근거가 있는 쪽을 택했다.

HW 진영 — InfiniGen

처음에는 PIM/CXL을 우선 검토했다. 그러나 PIM/CXL은 메모리 계층 자체를 확장하는 시스템·하드웨어 범위의 접근으로, 본 과제의 비교 범위인 모델 구조 수준의 KV Cache 절감과 동적 오프로딩·Prefetch 기반 관리보다 범위가 넓어 동일한 평가 범위에서 근거를 수집하기 어려웠다(기준③ 미충족). 반면 InfiniGen은 원본 KV Cache를 호스트 메모리에 유지하되 필요한 항목만 예측해 prefetch하므로, 메모리 효율·품질 보존·처리 지연·적용 조건을 조건별로 해석할 수 있다. 또한 공개 GitHub 구현체를 통해 논문 주장을 코드 수준에서 확인할 수 있다(기준②).

4. HW 접근의 정의

본 프로젝트에서 HW 접근은 신규 반도체·메모리 칩을 직접 설계하는 기술에 한정하지 않는다. GPU 외부 메모리 계층을 활용해 KV Cache 수용량을 확장하고, GPU와 외부 메모리 사이의 전송을 최적화하는 하드웨어 인지형 시스템 접근을 의미한다.

포함하는 것:

- GPU 외부 Host DRAM/CPU 메모리를 활용한 KV Cache 오프로딩 (예: InfiniGen)

- NVMe 스토리지 계층으로의 KV Cache 확장
- CXL 기반 메모리 확장 또는 PIM(Processing-in-Memory) 아키텍처

포함하지 않는 것:

- 어텐션 구조 자체를 재설계하는 모델 아키텍처 접근 (SW 진영으로 분류, 예: MLA)
- 사후 압축·양자화 알고리즘 (SW 진영으로 분류, 예: TurboQuant, KIVI)

5. 비교 원칙

두 논문의 실험 환경, 모델 구조, 기준 모델, 하드웨어 조건은 서로 다르다.
따라서 논문에 제시된 속도·정확도·메모리 수치를 직접 대결시키지 않는다.

대신 다음을 비교한다. (각 항목의 구체적 측정 기준은 C.4 장문맥 도메인 평가 기준에서 정의한다.)

- KV Cache 병목을 해결하는 방식
- 장문맥 환경에서의 메모리 효율
- 정확도 보존 가능성
- 장문맥 처리 지연
- 적용 조건과 도입 난이도

B. 설계

1. 기술 선정 방식

본 프로젝트는 Human 기반 기술 선정 방식을 적용한다.

단계	내용
1	KV Cache 최적화 기술을 SW 접근과 HW·인프라 접근으로 분류
2	장문맥 처리 적합성, 메모리 절감 방식, 정확도 평가 가능성 검토
3	SW 기술로 DeepSeek-V2 MLA 선정
4	HW·인프라 기술로 InfiniGen 선정
5	Agent가 선정된 기술의 근거를 수집·평가·종합

2. RAG 적용 대상

항목	내용
RAG 목적	두 기술의 원리, 실험 조건, 성능, 한계, 적용 조건을 원문 근거와 함께 추출
핵심 RAG Agent	기술 조사 Agent, 기술 성숙도 평가 Agent, 시장 평가 Agent, 도메인 평가 Agent
입력 문서	DeepSeek-V2 논문, InfiniGen 논문, 보조 공식 자료, 시장·산업 보고서
검색 단위	섹션, 문단, 표 설명, 그림 캡션, 실험 결과
칭킹 전략	칭크 크기 약 500토큰, overlap 50토큰 (표·그림 캡션은 별도 칭크로 분리 저장)
벡터 스토어	FAISS 기반 Dense 벡터 인덱스와 BM25 기반 Sparse 검색 인덱스를 구축
검색 방식	BGE-M3 Dense Top-25와 BM25 Sparse Top-25를 RRF로 결합하고, Top-20~30을 재정렬 후보로 사용
재정렬	2차: 오픈소스 Cross-encoder(BAAI/bge-reranker-v2-m3)로 재정렬 후 Top-5~8만 최종 컨텍스트로 사용
응답 원칙	주장·근거·출처·한계를 함께 출력하며, 근거가 부족한 경우 정보 부족 으로 표시
문서 제한	RAG 색인 대상 전체 200페이지 이내

3. RAG 문서 구성

문서군	문서	용도	예상 분량
기술 원문	DeepSeek-V2 논문	MLA 구조, KV Cache 압축, 성능·한계 추출	52쪽
기술 원문	InfiniGen 논문	Dynamic KV Cache 관리, Prefetch, 정확도·성능 추출	18쪽
보조 기술 자료	DeepSeek-V2 공식 GitHub README	실제 모델 구조, 128K 컨텍스트, MLA 적용·구현 조건 확인	약 5쪽 상당
보조 기술 자료	InfiniGen 공식 GitHub README	공개 구현, 재현 가능 여부, 정확도·속도 실험 스크립트 확인	약 5쪽 상당
도메인 자료	LongBench 논문	장문맥 이해를 어떤 과제로 평가하는지 정의	약 20쪽 이내
도메인 자료	RULER 논문	“지원 컨텍스트 길이”와 “실제로 활용 가능한 문맥 길이”를 구분하는 평가 근거	약 20쪽 이내
시장 자료	Gemini API Long Context 공식 문서 중 필요한 부분만 저장	장문맥 기능의 실제 활용 사례, 비용·지연·정확도 고려사항 확인	약 5~10쪽 상당
합계	RAG 색인 대상		약 130쪽 이내

4. Embedding 모델 후보 및 선정

후보 모델	장점	한계
BAAI/bge-m3	한국어·영어 지원, 긴 입력 처리, Dense-Sparse 검색 지원	상대적으로 무겁고 Hybrid 검색 구현이 복잡할 수 있음
intfloat/multilingual-e5-base	비교적 가볍고 구현이 단순	전문 기술 용어와 긴 문서 검색 성능을 별도 검증해야 함
all-MiniLM-L6-v2	빠르고 가벼움	한국어·영문 기술 논문 혼합 검색에 불리할 수 있음

최종 Embedding 모델

■ BAAI/bge-m3

항목	내용
선정 이유	영문 기술 논문과 한국어 질의를 함께 처리해야 함
기술 스펙	최대 입력 길이 8,192 토큰, Dense 임베딩 차원 1024, Dense-Sparse-Multi-vector(ColBERT 방식) 동시 지원
검색 전략	Dense Retrieval + Sparse Retrieval (본 설계에서는 Dense 임베딩만 사용하며 Sparse 검색은 BM25로 수행)
기대 효과	KV Cache, MLA, Offloading, Prefetch 같은 정확한 기술 용어와 의미 기반 질의를 함께 검색
한계	수식·표·그래프는 일반 텍스트 임베딩만으로 충분히 해석되지 않을 수 있음
대응	표·그림 캡션을 별도 청크로 저장하고, 답변에 원문 페이지·섹션을 함께 표시

5. Agent 정의

Agent	역할	RAG 여부	도구	입력	출력
기술 조사 Agent	기술 원리, 성능, 한계 추출	O	RAG 검색 도구 (BGE-M3 Dense + BM25 Sparse)	기술 논문	기술별 근거 요약
기술 성숙도 평가 Agent	공개 근거 기반 TRL 추정	O	RAG 검색 도구	논문, 구현·도입 자료	TRL 근거와 불확실성

Agent	역할	RAG 여부	도구	입력	출력
시장 평가 Agent	시장 수요, 상용화, 생태계 조사	O	RAG 검색 도구 + 외부 정보 검색 도구	공식 자료, 산업 자료	시장성 평가
이해관계자 평가 Agent	경쟁 기술 진영, 도입 기업 및 서비스 운영자, 투자·업계 관점의 이점·우려 분석	X	외부 정보 검색 도구	기술 조사 결과, 공개 웹 자료	이해관계자별 이점·우려·출처
도메인 평가 Agent	장문맥 처리 환경 적합성 평가	O	RAG 검색 도구	기술 논문, 장문맥 관련 자료	도메인 평가
평가 종합 Agent	관점별 결과와 충돌 지점 종합	X	(도구 없음 — LLM 추론)	모든 평가 결과	종합적 비교 결과
검증 Agent (Faithfulness Check)	claim-evidence 일치 여부 대조, 근거 부족 항목 탐지	X	근거 대조 도구 (Claim-Evidence 매칭)	synthesis, evidence_items, references	검증 통과/보류 판정
보고서 생성 Agent	결과를 보고서 형식으로 구성	X	(도구 없음 — LLM 생성)	종합 결과, 출처, 검증 결과	최종 보고서 초안

C. 평가 관점 및 기준

1. 선정 도메인

장문맥 처리 애플리케이션(Long-context Applications)

장문맥 처리 애플리케이션은 긴 문서, 긴 대화 이력, 코드 저장소, 연구 자료 등을 한 번에 읽고 분석·생성해야 하는 환경이다.

대표 활용 범위

- 긴 보고서·논문·계약서 질의응답
- 장문서 기반 RAG
- 긴 대화 이력을 유지하는 AI 비서
- 대규모 코드 저장소 분석
- 긴 문서 간 관계를 분석하는 리서치 Agent

2. 도메인 선정 사유

DeepSeek-V2의 MLA(Multi-head Latent Attention)는 KV Cache를 저차원 latent representation으로 압축하여 KV Cache의 저장 공간을 줄이고, 긴 컨텍스트를 처리할 때 발생하는 메모리 부담을 완화한다. 반면 InfiniGen은 긴 컨텍스트 처리 과정에서 증가하는 KV Cache를 GPU 외부의 메모리 계층으로 확장하여 관리하고, 필요한 KV Cache를 선택적으로 GPU로 가져오는 방식으로 GPU 메모리 부담을 줄인다.

두 기술은 KV Cache 병목 문제에 접근하는 방식에는 차이가 있지만, 컨텍스트 길이 증가에 따라 발생하는 메모리 요구량과 처리 부담을 완화한다는 공통점을 가진다.

따라서 본 프로젝트에서는 장문맥 처리 애플리케이션을 평가 도메인으로 선정하고, 장문맥 확장성, 메모리 효율, 정확도 보존, 처리 지연 및 적용 조건을 공통 기준으로 활용하여 두 기술의 특성과 한계를 비교 분석하고자 한다.

3. 4가지 평가 관점

평가 관점	평가 대상	평가 기준	핵심 질문
기술 성숙도	MLA, InfiniGen	공개 논문, 구현 공개 여부, 실제 적용 근거, TRL 추정	연구 단계인가, 실제 적용 가능성이 확인되었는가?
시장성	장문맥 LLM 관련 수요·생태계	상용화, 채택 사례, 프레임워크 지원, 확장성	이 기술을 필요로 하는 시장과 채택 동인이 있는가?
이해관계자	경쟁 기술 진영, 개발자, 도입 기업 및 서비스 운영자, 투자·업계 관계자	경쟁 기술의 대응, 기술 도입 비용 및 채택 장벽, 상용화 가능성 및 산업적 활용 가치	경쟁 기술 진영은 해당 기술에 어떻게 대응하며, 도입 기업과 서비스 운영자는 기술 도입 시 어떤 비용과 장벽을 고려하는가? 투자·업계 관계자는 해당 기술의 상용화 가능성과 산업적 가치를 어떻게 평가하는가?
도메인 적용성	장문맥 처리 애플리케이션	문맥 길이, 메모리 효율, 정확도, 지연 시간	긴 문서를 처리할 때 어떤 기술이 어떤 조건에서 적합한가?

4. 장문맥 도메인 평가 기준

평가 기준	확인 내용
장문맥 확장성	컨텍스트 길이 증가에 따른 KV Cache 부담 변화
메모리 효율	GPU HBM 및 외부 메모리 자원 활용 방식
정확도 보존	최적화 방식이 모델 출력 품질에 미치는 영향
처리 지연	압축·복원·메모리 전송 과정의 지연
문맥 활용성	긴 문맥 내 정보 활용과 최적화 방식의 관계
적용 난이도	모델 변경, 서빙 시스템 변경, 운영 조건

5. Agent 평가 Rubric

각 평가 Agent는 아래 Rubric에 따라 판정·근거·출처·한계·신뢰도를 함께 반환한다. 근거가 부족한 경우 억지로 판정하지 않고 정보 부족으로 표시한다. 기술 성숙도는 TRL 9단계 숫자 척도를 사용하며, 이는 공개 정보를 근거로 개발 단계를 절대적으로 위치시키는 목적이다.

반면 시장성·이해관계자 수용성·도메인 적합성은 상대적 우열로 읽히지 않도록 "근거 충분 / 근거 제한적 / 근거 부족" 3단계 정성 라벨로 표시하며, 이는 사전에 정의한 기준에 따라 근거 기반으로 산정하는 보조 지표다. 라벨은 관점별 평가를 구조화하기 위한 수단이며, 기술의 종합적인 우열이나 최종 추천을 의미하지 않는다.

5-1. 기술 성숙도 Rubric: TRL 1~9

TRL	판단 기준
1	기초 원리·이론이 관찰된 단계
2	기술 개념과 적용 가능성이 정의된 단계
3	실험실 수준의 개념 검증이 이뤄진 단계
4	구성 요소 또는 프로토타입이 실험 환경에서 검증된 단계
5	유사 실제 환경에서 구성 요소가 검증된 단계
6	실제 환경과 유사한 조건에서 시스템 수준 시연이 이뤄진 단계
7	실제 운용 환경에서 시제품이 시연된 단계
8	시스템 완성 및 상용 적용 적합성이 검증된 단계
9	실제 제품·서비스 환경에서 운영되는 단계

5-2. 시장성 Rubric: 근거 수준 3단계

근거 수준	판단 기준
근거 부족	장문맥 KV Cache 최적화 수요·상용화·생태계 근거가 거의 없거나, 연구 관심은 있으나 제품화·도입·프레임워크 지원 근거가 제한적임
근거 제한적	관련 오픈소스 프로젝트, 프레임워크 또는 초기 도입 사례가 존재함
근거 충분	주요 플랫폼·상용 서비스의 지원·도입 근거가 확인되거나, 다수 기업·플랫폼의 도입·제품화·생태계 지원 근거가 풍부함

5-3. 이해관계자 수용성 Rubric: 근거 수준 3단계

근거 수준	판단 기준
근거 부족	주요 이해관계자의 이점이 불명확하고 도입 위험이 크거나, 일부 이점은 있으나 정확도·비용·복잡도 우려가 더 큼
근거 제한적	이점과 우려가 혼재하며 특정 조건에서 도입 가능성이 있음
근거 충분	주요 이해관계자의 이점이 명확하고 도입 장벽 대응 방안이 존재하거나, 모든 이해관계자에 명확한 이점이 있고 도입 장벽도 구체적으로 관리 가능함

5-4. 장문맥 처리 애플리케이션 적합성 Rubric: 근거 수준 3단계

근거 수준	판단 기준
근거 부족	장문맥에서 메모리·정확도·지연 문제 개선 근거가 거의 없거나, 일부 개선 가능성은 있으나 장문맥 실험 또는 정확도 근거가 부족함
근거 제한적	장문맥에서 메모리 부담을 줄이고 정확도 또는 성능 유지 근거가 있음
근거 충분	메모리 효율과 정확도 보존 근거가 모두 있거나(적용 조건·제약 있음), 메모리 효율·정확도 보존·처리 성능 개선 근거가 함께 명확함

6. 평가 원칙

- 특정 기술을 최종 승자로 선정하지 않는다.
- 논문 결과와 Agent의 해석을 구분한다.
- 모든 평가는 근거와 출처를 함께 기록한다.
- 공개 정보 기반 TRL 추정의 한계를 명시한다.
- 관점 간 상충되는 결과를 제거하지 않고 보고한다.
- TRL은 기술의 개발 및 검증 수준을 9단계로 구조화하여 평가하는 척도이다. 본 프로젝트에서는 공개된 논문, 구현 자료, 적용 사례를 기반으로 기술 성숙도를 추정하며, 추정 결과를 실제 기술 개발 단계의 공식적인 판정과 동일하게 간주하지 않는다.
- TRL 구간별로 확보 가능한 공개 정보의 양이 다르다는 점을 감안한다. TRL 1~3은 학술 논문 중심으로 정보가 상대적으로 풍부하나, TRL 4~6은 영업비밀에 해당해 정보 갭이 크고, TRL 7~9는 수출·원가 등 핵심 지표가 비공개되어 일부만 공개된다. 따라서 구간에 따라 추정의 신뢰도 차이가 있음을 함께 기록한다.


D. 그래프 설계(안)

1. State 설계

State 이름	타입	설명	생성 Agent	사용 Agent
research_question	str	평가 요청 또는 세부 조사 질문	시작 Node	전체
selected_technologies	dict	MLA·InfiniGen 기술 기본 정보	초기화 Node(Human 선택)	전체

State 이름	타입	설명	생성 Agent	사용 Agent
			정값 로드)	
<code>retrieved_documents</code>	<code>list[Document]</code>	RAG 검색으로 확보한 근거 청크 — 기술 조사·기술성숙도평가는 기술원문(+구현자료), 시장평가는 시장자료(Gemini API 문서), 도메인평가는 기술원문과 도메인자료 (LongBench·RULER)를 검색	기술조사·기술성숙도평가·시장평가·도메인평가 Agent	종합·검증 Agent
<code>technical_evidence</code>	<code>dict</code>	원리, 성능, 한계, 실험 조건	기술 조사 Agent	기술 성숙도·시장·이해관계자·도메인·종합·검증 Agent
<code>trl_evaluation</code>	<code>dict</code>	기술 성숙도와 근거	기술 성숙도 평가 Agent	종합 Agent
<code>market_evaluation</code>	<code>dict</code>	시장성·생태계 조사 결과	시장 평가 Agent	종합 Agent
<code>stakeholder_evaluation</code>	<code>dict</code>	이해관계자별 이점·우려	이해관계자 평가 Agent	종합 Agent
<code>domain_evaluation</code>	<code>dict</code>	장문맥 처리 도메인 적합성	도메인 평가 Agent	종합 Agent
<code>references</code>	<code>list[dict]</code>	실제 사용한 문헌·웹 자료 목록. 여러 Agent 결과를 누적하고 URL 또는 문서 ID 기준으로 중복 제거	전체 Agent	평가 종합·검증·보고서 생성 Agent
<code>final_report</code>	<code>str</code>	최종 평가 보고서	보고서 생성 Agent	종료 Node
<code>synthesis</code>	<code>dict</code>	관점별 일치점 (<code>agreements</code>)·상충점 (<code>conflicts</code>)·기술별 유리한 조건 (<code>favorable_conditions</code>)을 담은 종합 결과	평가 종합 Agent	검증 Agent, 보고서 생성 Agent
<code>faithfulness_check</code>	<code>dict</code>	claim별 <code>evidence</code> ·원문 대조 결과, <code>pass</code> / <code>fail</code> , 근거 부족 claim, 재검색 필요 여부	검증 Agent	종료 판단 Node, 4개 관점 평가 Agent, 보고서 생성 Agent
<code>evaluation_rubric</code>	<code>dict</code>	TRL 1~9 기준과 시장성·이해관계자·장문맥 적합성의 근거 부족 / 근거 제한적 / 근거 충분 3단계 기준 및 필수 근거 규칙	초기화 Node	기술 성숙도 평가·시장·이해관계자·도메인 평가 Agent
<code>retry_count</code>	<code>int</code>	근거 보강을 위한 재검색 횟수	검증 Agent	종료 판단 Node
<code>max_retries</code>	<code>int</code>	허용하는 최대 재검색 횟수	초기화 Node	종료 판단 Node
<code>evidence_items</code>	<code>list[dict]</code>	<code>claim</code> , <code>evidence_quote</code> , <code>source_url</code> / <code>document_id</code> , <code>page_or_section</code> , <code>source_type</code> (RAG/external_search) , <code>limitation</code> 을 담은 공통 근거 목록	기술 조사·시장·이해관계자·도메인 평가 Agent	평가 종합·검증·보고서 생성 Agent

2. Graph 흐름 설계



3. 설계 원칙

- 관점별 결과는 별도 State에 저장한다.
- 병렬 Agent가 누적하는 retrieved_documents, references, evidence_items에는 list reducer를 적용하고, URL 또는 document_id 기준으로 중복을 제거한다.
- 모든 Agent는 결론뿐 아니라 근거·출처·한계·적용 조건을 함께 저장한다.
- 모든 평가 Agent는 사전에 정의된 Rubric에 따라 평가한다.
- 종합 Agent는 기술의 우열을 선언하지 않고, 관점별 일치점·상충점·기술별 유리한 조건을 정리한다.
- 보고서 생성 전 검증 Agent가 claim-evidence 일치 여부를 확인한다.
- 검증을 통과하지 못한 claim은 `정보 부족`으로 표시하거나, 최대 재검색 횟수 이내에서 근거 보강을 요청한다.
- 서로 다른 논문의 성능 수치는 실험 조건이 다를 수 있으므로 직접 비교하지 않는다.

E. 평가 보고서 목차(초안)

SUMMARY

- 평가 목적
- 비교 대상 기술
- 핵심 평가 결과
- 주요 교환관계와 시사점

1. 분석 배경

- 1.1 KV Cache의 역할
- 1.2 장문맥 처리에서 발생하는 KV Cache 병목
- 1.3 분석 목적 및 범위
- 1.4 HW 및 인프라 접근의 정의

2. 대상 기술 선정 및 기술 개요

- 2.1 비교 대상 선정 기준
- 2.2 DeepSeek-V2 MLA의 핵심 접근과 선정 이유
- 2.3 InfiniGen의 핵심 접근과 선정 이유
- 2.4 두 기술의 적용 범위와 구조적 차이
- 2.5 직접 성능 비교의 한계

3. Multi-Agent RAG 기반 평가 시스템 설계

- 3.1 평가 Agent의 역할 및 책임 분리
- 3.2 RAG 적용 Agent와 문서 활용 전략
- 3.3 RAG 문서 구성 및 출처 선정 기준
- 3.4 Embedding 모델 후보 비교 및 선정 근거
- 3.5 State Schema 및 Agent 간 데이터 흐름
- 3.6 Graph Workflow Loop Branch 설계
- 3.7 Faithfulness Check 및 평가 결과 검증 절차

4. 다관점 평가

- 4.1 기술 성숙도 관점
- 4.2 시장성 관점
- 4.3 이해관계자 관점
- 4.4 장문맥 처리 애플리케이션 관점

5. 종합 시사점

- 5.1 장문맥 환경에서 MLA가 유리한 조건
- 5.2 장문맥 환경에서 InfiniGen이 유리한 조건
- 5.3 메모리 효율, 품질 보존 근거, 처리 지연, 적용 조건 간의 차이
- 5.4 모델 구조 변경 가능성과 기존 인프라 호환성의 교환관계
- 5.5 두 접근을 함께 고려할 수 있는 조건

6. 한계 및 향후 과제

- 6.1 공개 정보 기반 평가의 한계
- 6.2 서로 다른 실험 환경을 비교하는 한계
- 6.3 확장편향 방지를 위해 취한 검증 조치
- 6.4 추가 실험이 필요한 지표

REFERENCE

1. DeepSeek-AI (2024). DeepSeek-V2: A Strong, Economical, and Efficient Mixture-of-Experts Language Model. arXiv:2405.04434. <https://arxiv.org/abs/2405.04434>
2. Lee, W., Lee, J., Seo, J., & Sim, J. (2024). InfiniGen: Efficient Generative Inference of Large Language Models with Dynamic KV Cache Management. USENIX OSDI 2024. <https://arxiv.org/abs/2406.19707>
3. Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., & Liu, Z. (2024). BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. arXiv:2402.03216. <https://arxiv.org/abs/2402.03216>
4. Bai, Y., Lv, X., Zhang, J., Lyu, H., Tang, J., Huang, Z., Du, Z., Liu, X., Zeng, A., Hou, L., Dong, Y., Tang, J., & Li, J. (2024). LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 3119–3137. <https://aclanthology.org/2024.acl-long.172.pdf>
5. Hsieh, C.-P., Sun, S., Krizan, S., Acharya, S., Rekesh, D., Jia, F., Zhang, Y., & Ginsburg, B. (2024). RULER: What's the Real Context Size of Your Long-Context Language Models? COLM 2024. arXiv:2404.06654. <https://arxiv.org/pdf/2404.06654>
6. Google (2026-06-22). 긴 컨텍스트 (Long context). Gemini API Docs, Google AI for Developers. <https://ai.google.dev/gemini-api/docs/long-context>
7. DeepSeek-AI (2024-09-25). DeepSeek-V2 GitHub Repository. Github. <https://github.com/deepseek-ai/DeepSeek-V2>
8. SNU Computer Architecture Lab (2024-07-10). InfiniGen GitHub Repository. Github. <https://github.com/snu-comparch/infinigen>